

Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО
ITMO University

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
GRADUATION THESIS

Метод классификации воображаемых движений рук человека в режиме реального времени на основе данных электроэнцефалографии

Обучающийся / Student Лунев Артем Евгеньевич

Факультет/институт/кластер/ Faculty/Institute/Cluster факультет программной инженерии и компьютерной техники

Группа/Group Р4223

Направление подготовки/ Subject area 09.04.04 Программная инженерия

Образовательная программа / Educational program Нейротехнологии и программная инженерия 2022

Язык реализации ОП / Language of the educational program Русский

Квалификация/ Degree level Магистр

Руководитель ВКР/ Thesis supervisor Билый Андрей Михайлович, доцент, доктор медицинских наук, Университет ИТМО, факультет программной инженерии и компьютерной техники, доцент (квалификационная категория "ординарный доцент")

Обучающийся/Student

Документ подписан	
Лунев Артем Евгеньевич	
04.06.2024	

(эл. подпись/ signature)

Лунев Артем
Евгеньевич

(Фамилия И.О./ name
and surname)

Руководитель ВКР/
Thesis supervisor

Документ подписан	
Билый Андрей Михайлович	
03.06.2024	

(эл. подпись/ signature)

Билый Андрей
Михайлович

(Фамилия И.О./ name
and surname)

**Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО
ITMO University**

**АННОТАЦИЯ
ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЫ
SUMMARY OF A GRADUATION THESIS**

Обучающийся / Student Лунев Артем Евгеньевич

Факультет/институт/кластер/ Faculty/Institute/Cluster факультет программной инженерии и компьютерной техники

Группа/Group P4223

Направление подготовки/ Subject area 09.04.04 Программная инженерия

Образовательная программа / Educational program Нейротехнологии и программная инженерия 2022

Язык реализации ОП / Language of the educational program Русский

Квалификация/ Degree level Магистр

Тема ВКР/ Thesis topic Метод классификации воображаемых движений рук человека в режиме реального времени на основе данных электроэнцефалографии

Руководитель ВКР/ Thesis supervisor Билый Андрей Михайлович, доцент, доктор медицинских наук, Университет ИТМО, факультет программной инженерии и компьютерной техники, доцент (квалификационная категория "ординарный доцент")

**ХАРАКТЕРИСТИКА ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЫ
DESCRIPTION OF THE GRADUATION THESIS**

Цель исследования / Research goal

Целью данной работы является повышение точности классификации воображаемых движений рук человека на основе данных ЭЭГ.

Задачи, решаемые в ВКР / Research tasks

Для достижения поставленной цели поставлены следующие задачи: 1. Провести обзор и анализ существующих решений и подходов к разработке интерфейсов мозг-компьютер; 2. Провести сбор данных ЭЭГ на оборудовании NeoRec cap 16 PROFESSIONAL; 3. Разработать и реализовать в виде программного продукта модель причинно-следственных связей между сигналами мозга и движениями рук; 4. Провести экспериментальные исследования, подтверждающие достижение цели; 5. Провести апробацию результатов исследования.

Краткая характеристика полученных результатов / Short summary of results/findings

В ходе научно-исследовательской работы были исследованы современные результаты в области интерфейсов мозг-компьютер. Был разработан алгоритм классификации воображаемых движений человека по данным электроэнцефалографии на основе искусственных нейронных сетей. Представлен подход к обучению нейронной сети с использованием техники Transfer learning, которая позволила увеличить точность классификации в среднем на 4%. В результате в офлайн режиме удалось добиться средней точности классификации в 62%. Двое из трех испытуемых затем смогли улучшить свой

показатель точности в среднем на 11% за счет тренировки в онлайн режиме с обратной связью.


Наличие публикаций по теме выпускной работы / Publications on the topic of the thesis

- 1. Лунев А.Е. Модель для разработки интерфейсов мозг-компьютер на основе классификации воображаемых движений рук человека с помощью электроэнцефалограммы//Сборник тезисов докладов конгресса молодых ученых - 2024 (Тезисы)
- 2. Лунев А.Е., Билый А.М. Классификация воображаемых движений рук человека на основе данных электроэнцефалографии // Вестник психофизиологии -2024. - № 2. - С. (Статья; ВАК, РИНЦ)

Наличие выступлений на конференциях по теме выпускной работы / Conference reports on the topic of the thesis

- 1. XIII Конгресс молодых ученых ИТМО (КМУ 2024), 08.04.2024 - 11.04.2024 (Конгресс, статус - всероссийский)

Обучающийся/Student

Документ подписан	
Лунев Артем Евгеньевич	
04.06.2024	

(эл. подпись/ signature)

Лунев Артем
Евгеньевич

(Фамилия И.О./ name
and surname)

Руководитель ВКР/
Thesis supervisor

Документ подписан	
Билый Андрей Михайлович	
03.06.2024	

(эл. подпись/ signature)

Билый Андрей
Михайлович

(Фамилия И.О./ name
and surname)

**Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО
ITMO University**

**ЗАДАНИЕ НА ВЫПУСКНУЮ КВАЛИФИКАЦИОННУЮ РАБОТУ /
OBJECTIVES FOR A GRADUATION THESIS**

Обучающийся / Student Лунев Артем Евгеньевич

Факультет/институт/кластер/ Faculty/Institute/Cluster факультет программной инженерии и компьютерной техники

Группа/Group P4223

Направление подготовки/ Subject area 09.04.04 Программная инженерия

Образовательная программа / Educational program Нейротехнологии и программная инженерия 2022

Язык реализации ОП / Language of the educational program Русский

Квалификация/ Degree level Магистр

Тема ВКР/ Thesis topic Метод классификации воображаемых движений рук человека в режиме реального времени на основе данных электроэнцефалографии

Руководитель ВКР/ Thesis supervisor Билый Андрей Михайлович, доцент, доктор медицинских наук, Университет ИТМО, факультет программной инженерии и компьютерной техники, доцент (квалификационная категория "ординарный доцент")

Характеристика темы ВКР / Description of thesis subject (topic)

Тема в области фундаментальных исследований / Subject of fundamental research: нет / not

Тема в области прикладных исследований / Subject of applied research: да / yes

Основные вопросы, подлежащие разработке / Key issues to be analyzed

Целью работы является повышение точности классификации воображаемых движений рук человека на основе данных ЭЭГ

Для достижения данной цели поставлены следующие задачи:

1. Провести обзор и анализ существующих решений и подходов к разработке интерфейсов мозг-компьютер.
2. Провести сбор данных ЭЭГ на оборудовании NeoRec cap 16 PROFESSIONAL.
3. Разработать и реализовать в виде программного продукта модель причинно-следственных связей между сигналами мозга и движениями рук.
4. Провести экспериментальные исследования, подтверждающие достижение цели.
5. Провести апробацию результатов исследования.

Методические рекомендации:

1. Korik A. et al. Decoding imagined 3D arm movement trajectories from EEG to control two virtual arms—a pilot study //Frontiers in neurorobotics. 2019. V. 13. P. 94.

Форма представления материалов ВКР / Format(s) of thesis materials:

Отчет, презентация

Дата выдачи задания / Assignment issued on: 25.01.2024

Срок представления готовой ВКР / Deadline for final edition of the thesis 30.05.2024

СОГЛАСОВАНО / AGREED:Руководитель ВКР/
Thesis supervisor

Документ подписан	
Билый Андрей Михайлович	
26.04.2024	


(эл. подпись)

Билый Андрей
МихайловичЗадание принял к
исполнению/ Objectives
assumed BY

Документ подписан	
Лунев Артем Евгеньевич	
26.04.2024	

(эл. подпись)

Лунев Артем
ЕвгеньевичРуководитель ОП/ Head
of educational program

Документ подписан	
Лисицына Любовь Сергеевна	
27.04.2024	

(эл. подпись)

Лисицына
Любовь
Сергеевна

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	8
1 ОБЗОР И АНАЛИЗ СУЩЕСТВУЮЩИХ РЕШЕНИЙ	13
1.1 Обзор методов предобработки сигнала	13
1.2 Обзор методов классификации признаков.....	19
1.3 Обзор схожих решений.....	23
2 СБОР ДАННЫХ	27
2.1 Оборудование для сбора данных	27
2.2 Методика сбора данных.....	29
3 МОДЕЛЬ КЛАССИФИКАЦИИ ВООБРАЖАЕМЫХ ДВИЖЕНИЙ	32
3.1 Предобработка данных	32
3.2 Архитектура нейронной сети.....	33
3.3 Процесс обучения нейронной сети	37
3.4 Используемые инструменты	40
4 РЕЗУЛЬТАТЫ ЭКСПЕРИМЕНТАЛЬНЫХ ИССЛЕДОВАНИЙ.....	42
4.1 Оценка способности испытуемых к совершению воображаемых движений.....	42
4.2 Результаты эксперимента в оффлайн режиме	43
4.3 Результаты эксперимента в онлайн режиме	44
4.3.1 Первый испытуемый.....	45
4.3.2 Второй испытуемый	46
4.3.3 Третий испытуемый	47
4.3.4 Анализ результатов экспериментов в онлайн режиме	48

ЗАКЛЮЧЕНИЕ	50
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	52

ВВЕДЕНИЕ

В настоящее время с каждым годом растет популярность направления под названием «Интерфейсы мозг-компьютер» (ИМК) [1]. Данная технология позволяет получить возможность контактирования с внешним миром через активность мозга. На сегодняшний день данные разработки чаще всего применяются для реабилитации пациентов после различных травм и неврологических нарушений, например инсульта [2-3]. Для некоторых парализованных людей, неспособных управлять своими мышцами, технология ИМК становится единственным вариантом общения с внешним миром. Также существуют немногочисленные исследования, в которых демонстрируется возможность улучшать результаты спортсменов и киберспортсменов после тренировок воображаемых движений с обратной связью от ИМК [4].

Инвазивные ИМК включают в себя имплантацию электродов или других устройств непосредственно в ткани мозга. Это позволяет более точно записывать и стимулировать активность мозга, что делает их эффективными для передачи сигналов и получения данных высокого разрешения. Однако инвазивные методы часто связаны с риском осложнений и требуют хирургического вмешательства. Поэтому на сегодняшний день исследователи чаще всего выбирают неинвазивные методы, которые регистрируют сигналы мозга без вмешательства в него. Одним из популярных и доступных методов, с помощью которого возможна регистрация мозговой активности, является электроэнцефалография (ЭЭГ). Данный метод измеряет разность потенциалов в различных участках мозга, которая возникает из-за слабых электрических токов в нейронах мозга. Среди преимуществ ЭЭГ выделяют высокое временное разрешение, а к недостаткам относят низкое пространственное разрешение и высокую чувствительность к мышечной активности и различным внешним шумам.

Для подачи сигнала на внешнее устройство с помощью ИМК, испытуемый может выполнять разные ментальные задачи, из которых будет декодироваться нужная информация. Такими задачами могут быть внутреннее произношение мысленной речи [5], представление визуальных образов [6] и т.д. Но самой популярной задачей, используемой в интерфейсах мозг-компьютер, является воображение движений [7-12]. Данная задача представляет собой когнитивный процесс мышления о движении части тела, например, правой руки, без его реального выполнения. При этом испытуемый должен пытаться концентрироваться на воображении своей мышечной активности, а не визуальном образе, представляя себя со стороны делающим движение.

В настоящее время удалось добиться значительных успехов в задачах распознавания воображаемых движений. В последних исследованиях для решения этой задачи все чаще используются подходы, основанные на искусственных нейронных сетях [9-12]. Например, в масштабном исследовании [9], в котором анализировалось 5 датасетов с воображаемыми движениями рук человека авторам удалось добиться средней точности в 88,6% для 280 испытуемых в задаче бинарной классификации воображаемых движений правой и левой рук. Также популярным датасетом для классификации воображаемых движений является BCI Competition IV-2a [13], который содержит 4 типа движения (движения левой рукой, правой рукой, обеими ступнями и языком) для 9 испытуемых. В различных статьях [10-12] для данного датасета удается добиться хорошей точности классификации от 77% до 85% для 4 классов.

Тем не менее достаточно мало статей посвящено распознаванию конкретных движений с заданными траекториями, в частности движений рук. Представление конкретных движений рук является наиболее естественным способом выполнения различных задач, например контроля протеза. В одной из статей [8] была разработана система по управлению виртуальными руками. Но средняя точность распознавания одной из трех целей движения руки по

предсказанной траектории составила всего 45% (при случайном уровне в 33,3%).

Таким образом, актуальность темы выпускной работы обусловлена развитием технологии ИМК и способов ее применения. В частности, на текущий момент не удалось добиться хороших результатов в задаче классификации воображаемых движений рук человека с заданными траекториями. Также довольно мало работ посвящено исследованию возможности тренировки испытуемых в онлайн режиме с обратной связью от ИМК для повышения точности классификации.

Целью данной работы является повышение точности классификации воображаемых движений рук человека на основе данных ЭЭГ.

Для достижения данной цели поставлены следующие задачи:

1. Провести обзор и анализ существующих решений и подходов к разработке интерфейсов мозг-компьютер;
2. Провести сбор данных ЭЭГ на оборудовании NeoRes cap 16 PROFESSIONAL;
3. Разработать и реализовать в виде программного продукта модель причинно-следственных связей между сигналами мозга и движениями рук;
4. Провести экспериментальные исследования, подтверждающие достижение цели;
5. Провести апробацию результатов исследования.

Объектом исследования являются данные ЭЭГ человека при воображении движений рук.

Предметом исследования является модель причинно-следственных связей между сигналами мозга и движениями рук с обратной связью для повышения точности классификации движений.

Для решения задач использовались теоретические и эмпирические методы исследования, включающие в себя анализ, наблюдение, сравнение, эксперимент, измерение.

Методологической и теоретической основой послужили научные труды в областях машинного обучения и анализа данных, нейрофизиологии, нейротехнологий, взятые с таких ресурсов как IEEE, scienceDirect, Frontiers и eLIBRARY.

По результатам ВКР в рамках апробации, можно выделить статью, которая на момент написания ВКР принята к публикации и выступление на конференции:

- Лунев А.Е., Билый А.М. Классификация воображаемых движений рук человека на основе данных электроэнцефалографии // Вестник психофизиологии (ВАК, РИНЦ).
- Лунев А.Е. Модель для разработки интерфейсов мозг-компьютер на основе классификации воображаемых движений рук человека с помощью электроэнцефалограммы. XIII Конгресс молодых ученых (г. Санкт-Петербург, Университет ИТМО), 08.04.2024 – 11.04.2024, Всероссийская конференция.

Структура выпускной квалификационной работы включает в себя введение, четыре главы с описанием работы и заключение.

В первой главе представлен обзор и анализ предметной области. В нем обобщаются вопросы предобработки ЭЭГ сигнала и извлечение из него признаков, методы классификации машинного обучения, а также рассматриваются некоторые работы исследователей по схожим задачам классификации ЭЭГ данных.

Вторая глава содержит информацию об оборудовании для записи ЭЭГ и о процессе сбора данных.

В третьей главе описывается разработанный алгоритм классификации воображаемых движений. Описывается предобработка данных, архитектура нейронной сети и процесс ее обучения.

Четвертая глава содержит описание полученных результатов. Оценивается способность нейронной сети к декодированию воображаемых движений, а также подробно описывается тренировка каждого испытуемого в режиме с обратной связью.

В заключении подводятся итоги работы и содержится описание полученных результатов.

1 ОБЗОР И АНАЛИЗ СУЩЕСТВУЮЩИХ РЕШЕНИЙ

1.1 Обзор методов предобработки сигнала

Одной из задач предобработки сигнала ЭЭГ является увеличение соотношения сигнал-шум. Большинство шума исходит от мышечной активности испытуемого, таких как моргание, глотание, поворотов головы и т. д. Так как данная часть сигнала не несет в себе полезной информации, по возможности ее необходимо уменьшить, или отфильтровать специальными алгоритмами. Другой задачей обработки исходного сигнала является извлечение из него признаков, которые подаются на вход классификатору, относящему участок сигнала к определенному действию. В данной главе рассматриваются методы решающие эти задачи.

Преобразование Фурье — один из старейших и наиболее широко используемых методов обработки сигналов [14]. Данная операция сопоставляет исходной функции другую функцию, которая описывает амплитуду и фазу каждой синусоиды, соответствующей определённой частоте. В результате из новой, полученной функции можно понять частотно-амплитудное соотношение в сигнале. Исходный сигнал $f(t)$ переводится в спектральное представление с помощью формулы прямого преобразования Фурье (1).

$$f(w) = \int_{-\infty}^{+\infty} f(t)e^{-itw} dt \quad (1)$$

Так как ЭЭГ сигнал представляет собой дискретную функцию, в данном случае необходимо применять дискретное преобразование Фурье (ДПФ), которое определяется формулой (2). Оно является частным случаем преобразования Фурье.

$$X_k = \sum_{n=0}^{N-1} x_n e^{-\frac{2\pi i}{N} kn} \quad (2)$$

Обратное преобразование Фурье представлено формулой (3) и позволяет вернуться к исходному сигналу. Также оно может использоваться для фильтрации исходного сигнала.

$$x_n = \frac{1}{N} \sum_{k=0}^{N-1} X_k e^{\frac{2\pi i}{N} kn} \quad (3)$$

На практике чаще всего применяются алгоритмы быстрого преобразования Фурье, которые существенно уменьшают вычислительную сложность. Их суть состоит в разбиении исходного сигнала на несколько частей для которых вычисляется преобразование Фурье, после чего из них формируется результат преобразования Фурье исходного сигнала. К главным недостаткам данного алгоритма относится потеря информации о временной структуре сигнала.

Другим популярным методом выделения признаков является **авторегрессионная модель**. Данная модель позволяет оценить значения сигнала, используя линейно взвешенную сумму предыдущих значений.

Подробно использование векторной авторегрессионной модели (ВАР), способной работать с несколькими временными рядами, приведено в статье «Некоторые вопросы исследования корково-корковых функциональных связей с помощью векторной авторегрессионной модели многоканальной ЭЭГ» [15]. Допустим, задача состоит в построении ВАР модели для ЭЭГ сигнала с M каналами длительностью в N отсчетов. В каждый дискретный

момент времени n ($1, 2, \dots, N$) этот отрезок характеризуется M значениями электрического потенциала, которые можно представить в виде M -мерного вектор-столбца: $x(n) = [x_1(n), x_2(n), \dots, x_M(n)]^T$, где $x_m(n)$ – значение электрического потенциала в канале с номером m . Тогда модель порядка P представляет произвольное значение $x(n)$ сигнала представляет в виде линейной комбинации p предыдущих значений и текущего вектора белого гауссового шума $e(n) = [e_1(n), e_2(n), \dots, e_M(n)]^T$ (4):

$$x(n) = \sum_{p=1}^{p=P} a(p)x(n-p) + e(n), \quad (4)$$

где $a(p)$ обозначает квадратную матрицу размерности M , элементы которой $a_{km}(p)$ показывают, какой вклад в текущее значение сигнала $x_k(n)$ в канале k вносит сигнал $x_m(n-p)$ в канале m .

К условиям применения ВАР модели относятся нормальность распределения многоканального сигнала $x(n)$ и слабая стационарность ЭЭГ сигнала.

Наиболее часто данная модель используется для построения оценки спектральной плотности сигнала, что позволяет выделить интервалы ЭЭГ сигнала, на которых произошли изменения. Также она используется для оценки связности ЭЭГ каналов. Реже, в качестве признаков используются коэффициенты модели при оценке исходного ЭЭГ сигнала. На практике порядок данной модели и соответственно количество ее коэффициентов при предыдущих значениях ряда варьируется от 4 до 15 и выбирается по различным критериям в зависимости от задачи.

Более новой техникой предобработки сигнала является **вейвлет-преобразование** [16]. Оно может использоваться как для очищения сигнала от шума, так и извлечения признаков из сигнала. Суть данной техники

заключается в разложении сигнала по базису, представляющему собой множество вейвлетов. Данное преобразование переводит сигнал из временного представления в частотно-временное, что позволяет скомбинировать информацию о частотах и времени в отличие от преобразования Фурье и авторегрессионной модели. Также этот метод лучше работает для нестационарных сигналов (то есть сигналов с различными частотами на разных временных интервалах). Одной из разновидностью данного преобразования является пакетное дискретное вейвлет-преобразование (DWPT). При анализе ЭЭГ данных, для его разложения на гармонические составляющие часто используются вейвлеты Морле, которые задаются формулой (5):

$$\Psi(t) = A \cos(2\pi f t) * w(t), \quad (5)$$

где t = время; f = частота вейвлета; $w(t) = \exp(-t^2/Fb)$ – экспоненциальные множители или колоколообразное Гауссово окно (огибающая для косинуса); Fb – масштаб вейвлета, определяющий его ширину по оси t ; $A=1/\sqrt{\pi Fb}$ – нормирующий множитель.

Среди недостатков вейвлет преобразования часто выделяют ее большую вычислительную сложность.

Фильтр Калмана – рекурсивный фильтр, оценивающий неизвестные параметры текущего состояния динамической системы на основе предыдущих измерений, содержащих шум и неточности [17]. Преимуществом данного фильтра является простота использования для анализа данных в реальном времени, а также возможностью работы с сильно зашумленным сигналом. Фильтр Калмана работает во временном, а не частотном представлении.

Недостатком вышеописанных методов является их независимый анализ каждого сигнала и соответственно невозможность учесть пространственное

распределение электродов на голове человека при обработке многоканального сигнала. Примером метода обработки многоканального сигнала с учетом его пространственных характеристик является **фильтр Лапласа**. Данный фильтр обычно используется для обработки изображений, но можно встретить работы [18], посвященные его применению в обработки сигнала.

Более популярным методом обработки многоканального сигнала является **общий пространственный шаблон (CSP)** [14,19]. Он работает по принципу максимизации дисперсии между разными классами ЭЭГ сигналов и минимизации дисперсии внутри этих классов. Другими словами, данный метод проецирует многоканальный ЭЭГ сигнал в подпространство, где различие между классами более явное. При этом вычисляется компонент w^T следующим образом (6):

$$w = \underset{w}{\operatorname{argmax}} \frac{\|wX_1\|^2}{\|wX_2\|^2}, \quad (6)$$

где w – это пространственная матрица фильтров, а матрицы X_1 размера (n, t_1) и X_2 размера (n, t_2) представляют собой окна ЭЭГ сигнала с n каналами и количеством временных отсечек t_1 и t_2 соответственно.

К недостаткам данного алгоритма можно отнести то, что он никак не учитывает временные характеристики ЭЭГ сигнала. Существуют различные модификации данного алгоритма. Некоторые из них, такие как, например WCSP, CSSSP, решают проблему того, что для некоторых мозговых активностей отдельные ЭЭГ каналы несут в себе больше полезной информации, чем другие, из-за своего расположения. Другой популярной модификацией является банк фильтров (FBCSP) [20]. В нем сигнал ЭЭГ подвергается полосовой фильтрации в нескольких частотных диапазонах, после чего необходимые признаки извлекаются из каждого диапазона по

отдельности. Это в том числе необходимо из-за различий рабочих частотных полос для разных субъектов.

Из недавних методов извлечения признаков можно выделить применение **автокодировщиков**. Автокодировщик это архитектура нейронной сети, которая обучается без учителя. Зачастую такая нейронная сеть содержит 3 слоя – входной, скрытый и выходной, причем размерность выходного слоя совпадает с размерностью входного, а размерность скрытого слоя меньше размерности двух других. Суть работы сети заключается в том, чтобы на выходе выдать то же самое, что и на входе. Но так как скрытый слой имеет меньшую размерность, нейронной сети придется найти обобщение входных данных для их сжатия. В работе «Unsupervised feature extraction with autoencoders for EEG based multiclass motor imagery BCI» [7] предлагается подавать на вход автокодировщику участок ЭЭГ сигнала, после чего выделить вектор весов нейросети, который минимизирует отклонение входного сигнала на выходе и после некоторых преобразований использовать этот вектор весов в SVM классификаторе. Авторы данной статьи получили высокую точность распознавания движений – около 95%.

Извлечение признаков с помощью **генетических алгоритмов** довольно редко используется в задачах ИМК, но тем не менее данный метод применяется для извлечения признаков, например для классификации на основе потенциала P300 в статье «A genetic algorithm for automatic feature extraction in P300 detection» [21]. Генетические алгоритмы представляют собой эвристический алгоритм поиска, где во время поиска оптимальных параметров используются механизмы, аналогичные природному естественному отбору. Задача ставится таким образом, чтобы её решение могло быть закодировано в виде вектора («генотипа») генов. В начале некоторым образом создается множество начальных генотипов, для которых может быть вычислена функция приспособленности. Далее с помощью таких методов как наследование, мутации, отбор и кроссинговер моделируется эволюционный

процесс и отбираются лучшие параметры, соответствующие функции приспособленности.

1.2 Обзор методов классификации признаков

Данный класс алгоритмов выполняет функцию трансляции извлеченных признаков в команды внешнему миру.

Одним из простых, но довольно эффективным методом классификации является **линейный дискриминантный анализ, LDA** (множественный дискриминантный анализ, MDA, для разделения на более чем два класса). Для разделения классов, данный алгоритм строит линейную разделяющую гиперплоскость. Особенно часто данный алгоритм применяется совместно с алгоритмом CSP.

Алгоритм начинается с того, что рассчитываются ковариационные матрицы между классами (7) и внутри классов (8):

$$S_B = \sum_{k=1}^K (\mu_k - \mu)^T (\mu_k - \mu) \quad (7)$$

$$S_W = \sum_{k=1}^K \sum_{i \in C_k} (x_i - \mu_k)^T (x_i - \mu_k), \quad (8)$$

где x – это вектор признаков, μ_k – среднее значение признаков класса k , μ – среднее значение среди всех признаков.

После этого находятся собственные вектора для линейного дискриминанта Фишера, который определяется отношением матриц. Далее полученные собственные вектора сортируются в порядке убывания по собственным значениям и называются дискриминантными векторами, с помощью которых рассчитываются веса модели (9):

$$w = \mu_k d_v d_v^T, \quad (9)$$

где d_v – дискриминантный вектор. Итоговые прогнозируемые классы являются максимальной оценкой линейной комбинации векторов признаков и весов.

Среди условий применения данного алгоритма выделяют равенство ковариационных матриц гауссиан для каждого класса, нормальность независимых переменных и наличие линейной зависимости между переменными (мультиколлинеарность).

Из проблем данного алгоритма можно выделить невозможность эффективно решить задачу нелинейной классификации, а также большую чувствительность к выбросам. Но существуют различные варианты этого алгоритма такие как QDA, FDA, KDA, которые могут справляться с более сложными зависимостями между признаками и классами. Большим плюсом алгоритмов CSP и LDA является интерпретируемость результатов. Есть возможность оценить важность каждого признака и его место в исходном сигнале.

Метод опорных векторов (SVM), как и LDA, использует гиперплоскости для деления на разные классы. Основное различие между ними заключается в применении оптимальной гиперплоскости, которая максимизирует расстояние между гиперплоскостью и объектами разделяемых классов. Благодаря оптимальной гиперплоскости SVM достигает более высокого обобщения для классификации.

Алгоритм SVM выбирает ту гиперплоскость, которая максимизирует отступ между классами. В данном случае, под отступом понимается характеристика, оценивающая на сколько типичным представителем своего класса, является объект. В случае линейной классификации отступ рассчитывается по формуле (10):

$$y_i(\langle w, x_i \rangle - b) \quad (10)$$

Классификаторы SVM могут быть преобразованы в нелинейные классификаторы путем преобразования пространства признаков в многомерное пространство с использованием функции ядра, обычно гауссовой или радиальной базисной функции. Среди недостатков алгоритма выделяют неустойчивость к выбросам и необходимость подбора параметров алгоритма при помощи кросс-валидации.

В последнее время в задачах классификации ЭЭГ паттернов стали набирать популярность классификаторы, основанные на концепции **римановой геометрии** (РГ) [19]. Концепция римановой геометрии предполагает рассмотрение метрического пространства, называемого римановым многообразием, которому принадлежат ковариационные матрицы проб. Для определения близости объектов вводится метрика расстояния между ковариационными матрицами этих объектов, определяемая формулой (11):

$$\delta_R(C_1, C_2) = \left[\sum_{i=1}^N \log^2 \lambda_i \right]^{1/2} \quad (11)$$

где $\lambda_i, i = 1 \dots N$ – это собственные числа матрицы $C_1^{-1}C_2$.

Сам алгоритм классификации на основе римановой геометрии, под названием Minimum Riemannian Distance to Mean (MRDM), является обобщением метода k ближайших соседей (KNN) для риманова многообразия, формулу выше для оценки близости объектов. Далее, как и для алгоритма KNN, у данного алгоритма в основе лежит предположение о том, что близкие объекты относятся к одному классу.

К минусам подходов на основе римановой геометрии относят сложность в интерпретируемости работы данного алгоритма, а к плюсам относительно небольшую вычислительную сложность.

Также в задачах интерфейса мозг-компьютер, как и во многих других областях, в качестве классификатора успешно используются **искусственные нейронные сети**. Их главное преимущество заключается в возможности аппроксимировать любую непрерывную функцию. К недостаткам можно отнести их время работы. Среди архитектур нейронных сетей, применимых к задаче классификации на основе ЭЭГ сигнала можно выделить многослойный персептрон (MLP), квантование векторов (LVQ), FIRNN, TDNN. Также в данных задачах применяется глубокие нейронные сети, часто с использованием CNN и LSTM.

При использовании нейросетей, в частности, можно выделить технику Transfer Learning, набирающую в последнее время все большую популярность в задачах обработки биологических сигналов [9]. Суть данной техники заключается в переносе накопленного нейросетью опыта при решении одной задачи на решение другой, похожей задачи. В качестве примера, иллюстрирующего данную технику, часто приводится задача классификации изображений. Например, нейросеть, обученную на задаче классификации большого количества изображений разных классов можно после этого обучить повторно на задаче классификации другого, меньшего, количества изображений других классов. При этом, общие знания по выделению признаков, полученные при обработке большого количества изображений останутся. В задаче обработки ЭЭГ данная техника чаще всего применяется следующим образом: сначала нейронная сеть обучается на данных всех испытуемых, после чего она дообучается на данных целевого испытуемого. Это помогает нейросети понять как межсубъектные паттерны, так и паттерны, характерные для конкретного испытуемого.

Не самым популярным, но все же применимым решением задачи классификации являются **Байесовские классификаторы** [22], такие как, например Байесовский LDA или скрытая Марковская модель (НММ). Данный тип классификатора устанавливает границы между классами на основе теории вероятностей и, в частности, теоремы Байеса.

1.3 Обзор схожих решений

В монографии «Нейротехнологии: нейро-бос и интерфейс мозг - компьютер» [23] содержится описание эксперимента по созданию интерфейса мозг-компьютер на основе электрографических паттернов, сопровождающих идеомоторные акты. Идеомоторные акты – это произвольные микродвижения, которые возникают при мысленном представлении двигательных действий. В данном эксперименте участникам предлагалось пройти курсором случайно сгенерированный лабиринт, используя 4 мысленных движений – руками, ногами и языком. При этом участники проходили 10 тренировок, во время которых учились управлять курсором, генерируя нужные ЭЭГ паттерны. Для классификации паттернов было разработано пять искусственных нейронных сетей, четыре из которых классифицировали четыре типа идеомоторных актов, а одна отделяла фоновую активность от целевых паттернов. Входной слой каждой сети состоял из 17 компонент, соответствующих числу ЭЭГ электродов. В основу классификаторов легли сети радиально-базисных функций. Они были представлены двумя слоями нейронов с настраиваемыми параметрами (центры и ширина слоев, веса). Настройка производилась с помощью соревновательных и градиентных алгоритмов.

В результате авторы приводят данные, указывающие на различие испытуемых в способности генерировать соответствующие паттерны. Двум из десяти обследуемых удалось генерировать паттерны лишь с 11% вероятностью. Пять самых успешных обследуемых добились точности классификации около 55%. При этом с прохождением тренировок точность

классификации значительно увеличивалась. Максимально эффективными оказались первые 4-5 тренингов. Также авторами приводятся результаты, демонстрирующие сходство между реальными и воображаемыми движениями, заключающееся в возникновении преддвигательного потенциала готовности в паттерне ЭЭГ.

В статье «Decoding Imagined 3D Arm Movement Trajectories From EEG to Control Two Virtual Arms» [8] авторы реализовали онлайн контроль виртуальных рук на основе электроэнцефалограммы. Для моделирования рук на экране был использован игровой движок unity. После первичного сбора данных с каждым испытуемым авторы дополнительно проводили две калибровочные сессии с обратной связью онлайн. Для моделирования траекторий было использована спектральная мощность μ , низких и высоких бета и низких гамма сигналов с помощью множественной линейной регрессии. После этого из этой траектории движения классифицировались по трем видам с помощью модели LDA. Итоговая точность классификации офлайн составила 45%, а точность распознавания руки, выполняющей движение (левой или правой) составила 70%.

В работе «BCI System using a Novel Processing Technique Based on Electrodes Selection for Hand Prosthesis Control» [24] авторами была распечатана на 3d принтере кисть руки, которая способна двигаться в 6 степенях свободы. Для ее управления использовалась плата FPGA. В качестве данных для обучения был выбран датасет из базы PhysioNet. Один из интересных приемов, который использовался для предобработки сигнала, заключался в кластеризации ЭЭГ электродов с помощью алгоритма Kmeans. В результате с полученными кластерами работа велась отдельно, а один электрод, не вошедший ни в один кластер, не использовался. Для классификации движений была использована нейронная сеть на основе многослойного перцептрона. В результате для классификации двух движений авторам удалось добиться точности в 93%.

Довольно знаковой работой в области ИМК, в которой описан подход к классификации ЭЭГ сигналов на основе сверточных нейронных сетей, стала статья «EEGNet: A Compact Convolutional Neural Network for EEG-based Brain-Computer Interfaces» [10]. Ее преимуществами стали низкая вычислительная сложность, хорошие показатели точности на разных задачах с ЭЭГ данными, включая классификацию воображаемых движений, а также интерпретируемость вычислений нейронной сети. Интерпретируемость достигалась за счет того, что ни одна операция свертки не затрагивала одновременно временный и пространственный домены. Далее последовали несколько улучшений архитектуры данной сети [11-12], такие как использование слоя временной свертки, популярной в обработке временных рядов и использование механизмов внимания. Таким образом, семейство данных архитектур достигает точности классификации 4 воображаемых движений из датасета BCI Competition IV-2a в 77-85%.

В таблице 1 представлены данные о результатах классификации различных алгоритмов на схожих задачах. Из данной таблицы можно сделать вывод, что классические методы машинного обучения [25-26] в настоящий момент не показывают самые высокие точности. Подходы, основанные на римановских геометриях [27-28] показывают достаточно близкие результаты к подходам, основанным на нейронных сетях [12, 29-31].

Таблица 1 – Сравнение различных алгоритмов классификации воображаемых движений

Статья	Метод извлечения признаков	Метод классификации	Количество типов движений	Движения	Точность
[25]	CSP	LDA	4	Л/П рука, язык, ступни	78,8%
[26]	CSP	SVM	3	Л/П рука, генерация слов	68,7%
[27]	Mutual Information	kNN+PT	4	Л/П рука, язык, ступни	82,7%
[28]	CSP	FGMRDM	2	Л/П рука	92,2%
[29]	Вейвлет	CNN	2	Л/П рука	78,9%
[30]	Фурье	CNN	2	Л/П рука	92,7%
[31]	—	CNN	4	Л/П рука, язык, покой	93,7%
[12]	—	CNN	4	Л/П рука, язык, ступни	85,3%

2 СБОР ДАННЫХ

2.1 Оборудование для сбора данных

В качестве оборудования для сбора данных был выбран комплект neorec cap от компании medical computer systems, Россия (рисунок 1).



Рисунок 1 – Комплект neorec cap

В данный комплект входит 16-канальный беспроводной ЭЭГ усилитель NB2-EEG16, закрепленный сзади и сам электродный шлем. К преимуществам данного шлема можно отнести гелевые электроды, показывающие качество

записи лучше сухих, но более сложными в использовании, а также материал электродов Ag/AgCl, имеющий низкую поляризацию. 16 чашечных Ag/AgCl электродов закреплены по системе 10-20 (рисунок 2). Один электрод является референтным и располагается на мочке уха, другие 15 расположены в отведениях Fp1, Fp2, F3, F4, C3, C4, P3, P4, O1, O2, T3, T4, Fz, Cz, Pz. Также к комплекту поставляется ПО, способное записывать сигнал в популярные форматы ЭЭГ, такие как edf, bdf, gdf, а также транслировать сигнал в LSL поток, с помощью чего его можно обрабатывать сторонними приложениями в онлайн режиме. Запись данных осуществлялась на частоте дискретизации 250 Гц.




Рисунок 2 – Система наложения электродов 10-20

2.2 Методика сбора данных

В качестве воображаемых движений рук для классификации было выделено 4 типа движений. Все они начинались из исходного положения, когда руки опущены и располагаются вдоль тела. Первый тип движения представляет собой подъем вытянутой правой руки до высоты уровня глаз по горизонтальной оси и последующее опускание руки по той же траектории до исходного положения. Второй тип движения отличается от первого только тем, что подъем и опускание происходят по вертикальной оси, то есть траектория движения перпендикулярна траектории первого типа. Третий и четвертый тип движения соответствуют первому и второму, за исключением того, что воображаемое движение совершается левой рукой.

Первый вариант методики сбора данных для тренировки классификатора предполагал совершение испытуемым движений одного типа подряд 20 раз, при этом чередуя их с реальными движениями. Предполагалось, что это поможет испытуемым лучше концентрироваться на воображаемых движениях, путем повторения одного и того же движения подряд, и, следовательно, приведет к улучшению классификатора. Но главной проблемой при таком подходе является то, что паттерны мозговой активности, присутствующие на ЭЭГ, незначительно изменяются с течением времени и могут быть выделены классификатором даже во временном интервале в одну минуту. По этой причине классификатор обучался отличать один временный промежуток записи повторяющихся движений от другого вместо того, чтобы выделить паттерны, соответствующие движениям в данном интервале. Классификатор, обученный на таких данных, показывал хорошие результаты на валидационной выборке из того же набора данных, но на принципиально новых данных, например записанных в другой день, он показывал процент классификации близкий к случайному. Возможно, такой подход к записи данных для обучения классификатора имел бы смысл, если бы было записано много различных блоков повторяющихся движений в разные отрезки времени, из-за чего

классификатору было бы проще выделить паттерны, отличающие одно движение от другого, а не паттерны, характерные для временного промежутка.

Итоговый подход к сбору тренировочных данных заключался в повторении испытуемым одного типа движения 3 раза подряд, которое он узнавал непосредственно до совершения воображаемых движений. Количество совершаемых подряд движений было выбрано эмпирически, исходя из результатов классификатора. Вероятно, 3 повторения подряд является оптимальным, из-за того, что за время совершения движений испытуемый лучше настраивается на движение и количество таких блоков по 3 движения оказывается достаточным, для того чтобы классификатор не обучался распознавать отрезки времени, соответствующие 3 движениям.

Движения состояли из пяти этапов - ожидание начала движения в исходном положении (1.5 сек), выполнение подъема вверх до конечного состояния (2.5 сек), задержка руки в конечном положении (1.5 сек), опускание руки в исходное положение (2.5 сек) и ожидание начала следующего цикла (1.5 сек). Всего движение длится 9,5 сек.

Во время записи ЭЭГ испытуемые находились в положении сидя, с открытыми глазами и следовали текстовым указаниям на экране перед ними при совершении движений. Важно, чтобы испытуемый не получал информацию о типе предстоящего движения за очень малое время до его начала, чтобы его реакция на это не отражалась в данных ЭЭГ и не мешала классификации движений. Поэтому данная информация появлялась на экране за 10 секунд до начала движения, также в текстовом виде. Пример текста, который видел испытуемый перед глазами изображен на рисунке 3.

Дополнительно было записано некоторое количество реальных движений всех 4 типов для их последующего использования в обучении классификатора. При совершении воображаемых движений испытуемых просили пытаться концентрироваться на мышечной активности, а не визуально представлять себя совершающим движение. Сбор данных

осуществлялся блоками по 10-15 минут, во время которых производилась запись различных типов движений в случайном порядке. В среднем за один день записи удавалось записать 4-5 блоков движений. Запись прекращалась при наступлении усталости испытуемых.



Рисунок 3 – Пример изображения, во время демонстрации которого испытуемый должен совершать постепенный воображаемый подъем руки

3 МОДЕЛЬ КЛАССИФИКАЦИИ ВООБРАЖАЕМЫХ ДВИЖЕНИЙ

В данной работе для решения задачи классификации был выбран подход на основе нейронных сетей, благодаря их гибкости, возможности моделировать сложные зависимости в данных, хорошей точности, способности автоматически выделять нужные признаки и улучшать качество модели при увеличении тренировочной выборки.

3.1 Предобработка данных

До тренировки нейронной сети сначала была произведена канальная z-нормализация данных. При этом каждый нормализатор вычисляет свои настраиваемые параметры на отдельном ЭЭГ канале и в итоге получается 16 нормализаторов на каждый канал. Также стоит отметить, что в данной работе применяется техника Transfer Learning, и сначала нейронная сеть обучается на данных всех испытуемых, поэтому и нормализаторы настраиваются на данных всех испытуемых, чтобы при обучении на данных целевого испытуемого не потерять согласованность. Нормализация позволяет привести данные каждого канала к одной шкале, после чего среднее значение в каждом канале становится 0, а стандартное отклонение 1.

Также использовалась аугментация тренировочных данных временным сдвигом. Так как человек не может исполнять воображаемые движения точно в заданные сроки, для каждого тренировочного движения оно сдвигается на -1, -0.5, 0.5 и 1 секунды, тем самым после аугментации с каждого воображаемого движения получается 5 тренировочных примеров. При этом, в результате сдвига, часть данных, соответствовала отрезку времени, где испытуемый ничего не воображал и ожидал команды.

После записи, данные были отфильтрованы с помощью FIR-фильтра по нижней границе в 2 Гц. Верхняя граница фильтрации не применялась, так как это не приводило к улучшению результатов. Методы отчистки данных от

шумов также не применялись, так как это также не приводило к улучшению результата в дальнейшем.

В результате на вход нейронной сети подается ЭЭГ сигнал в виде матрицы 16×2375 , где 16 это количество каналов и 2375 это количество временных отсечек, возникающих во время движения ($9,5 \text{ сек движения} * 250 \text{ Гц частота дискретизации оборудования}$).

3.2 Архитектура нейронной сети

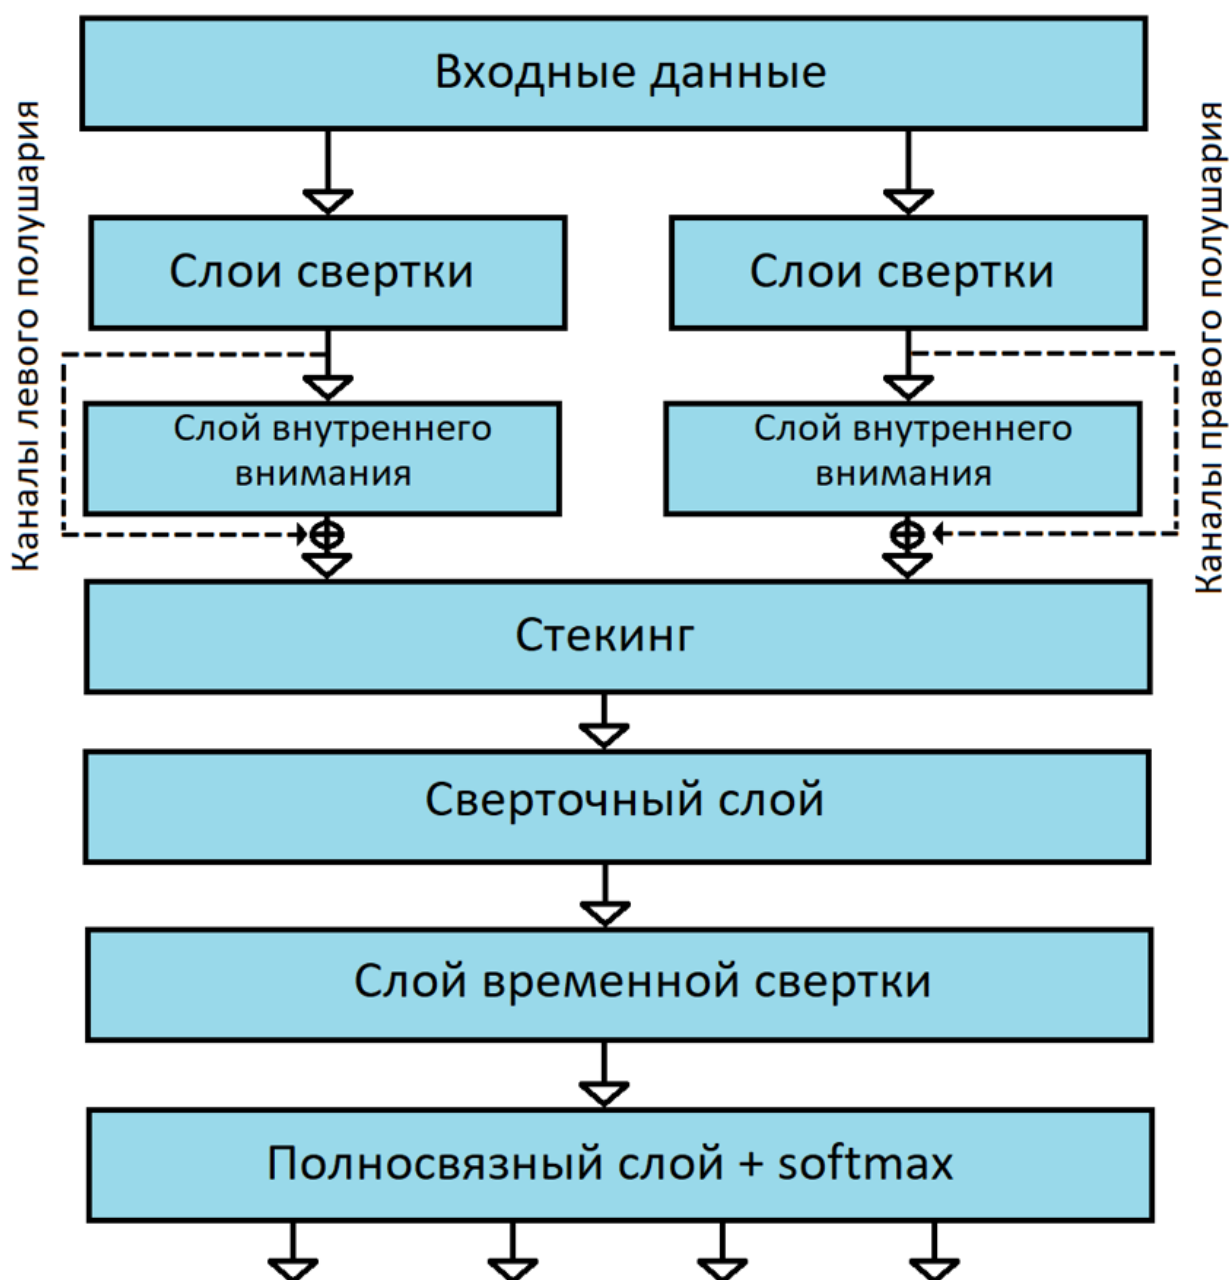


Рисунок 4 – Общая архитектура нейронной сети

Общая архитектура нейронной сети представлена на рисунке 4. Сначала входные данные отдельно разбиваются на две группы, которые обрабатываются независимо. В первой группе находятся данные ЭЭГ электродов, относящиеся к левому полушарию, а во второй – к правому. Центральные электроды дублируются в обе группы. В результате каждая группа представляет из себя матрицу 10×2375 . Данный подход был впервые применен в статье «EEGSym: Overcoming inter-subject variability in motor imagery based BCIs with deep learning» [9] и позволяет независимо подбирать веса нейронной сети, подходящие к активности разных полушарий.

После этого каждая группа попадает в последовательность сверточных слоев. Архитектура данных слоев представляет из себя сеть EEGNet [10], которая приобрела большую популярность в анализе ЭЭГ данных. Ее архитектура изображена на рисунке 5. Первый сверточный слой с ядром размером 1×64 , применяется для извлечения временных признаков, так как из-за размерности ядра, оно не объединяет данные разных каналов, а работает с 64 временными интервалами соответственно. При этом количество фильтров в свертке устанавливается в 16. Следующий сверточный слой с ядром размером 10×1 , применяется для извлечения пространственных, или канальных признаков, так как из-за размера ядра работает со всеми каналами по одному временному интервалу. После этого слоя каналы соединяются в один и последний сверточный слой с ядром 1×16 снова извлекает более высокоуровневые временные признаки.

Также после второго и третьего слоя сверток применяется средний пулинг, с ядрами размера 8 и 18 соответственно. Это стандартная техника, которая позволяет уменьшить размерность данных. После каждого сверточного слоя используется нормализация по батчам (batch normalization), для ускорения и стабилизации обучения, а также слой дропаута для предотвращения переобучения. В качестве нелинейной функции активации между слоями используется *elu*. После работы последовательности

сверточных слоев получается матрица размером 16×32 .




Рисунок 5 – Последовательность сверточных слоев

Далее после первой части следует слой внутреннего внимания с двумя головами внимания. Механизм внимания приобрел большую популярность после успеха моделей трансформера, найдя свое применение во многих задачах машинного обучения. Данный механизм позволяет моделям лучше учитывать взаимосвязи между частями входных данных, путем вычисления важности данных частей. Перед применением слоя внимания производится нормализация слоев (layer normalization) входных данных. Основными компонентами внимания являются query (матрица запросов), key (матрица ключей) и value (матрица значений). В данном случае все они одинаковые и являются матрицами размера 16×32 , полученными на предыдущем шаге. Реализация данного механизма взята из слоя MultiHeadAttention библиотеки keras. Также после вычисления внутреннего внимания используется техника пропуска соединений (residual connections) и к результату данного слоя прибавляется исходные данные, которые использовались как входные для этого слоя.

Далее данные двух групп объединяются в одну, путем стекинга, в результате чего получается матрица размером $2 \times 16 \times 32$, и последующей свертки с ядром 2×1 для того, чтобы вернуться к размерности данных 16×32 .

Как и прежде после слоя свертки применяются нормализация по батчам, дропаут и функция активации `elu`.

После этого идет слой временной сверточной сети. Временные сверточные сети являются популярным методом при анализе временных рядов. Их использование для анализа данных ЭЭГ было предложено в статье «An accurate temporal convolutional network for embedded motor-imagery brain-machine interfaces» [11]. Принцип работы временных сверточных сетей проиллюстрирован на рисунке 6. Данная сеть состоит из слоев, в которых от слоя к слою повышается параметр `dilation`, относящийся к ядру свертки. Данный параметр определяет интервал между элементами ядра свертки. Соответственно при его увеличении возрастает размер поля зрения ядра, но в нем появляются пропуски. При переходе от слоя к слою таких пропусков становится больше, пока значимым не останется один последний нейрон на последнем слое. Также в таких сетях необходимо применять `causal padding` для сохранения причинной структуры данных, чтобы предотвратить использование информации из будущих временных отрезков для вычисления текущего состояния. В данной работе на вход подается последовательность из 16 элементов размерности 32, а на выходе получается один элемент, соответствующий 1D вектору размерности 32. После каждого слоя применяются нормализация по батчам, дропаут и функция активации `elu`, как и прежде.




Рисунок 6 – Принцип работы временной свертки

В итоге выходной вектор размерности 32 подается на полносвязный слой с 4 выходными нейронами, соответствующие 4 классам воображаемых движений. В конце к выходным значениям применяется softmax функция, которая переводит их в вероятности отнесения к тому или иному классу, что является стандартным для задачи классификации.

3.3 Процесс обучения нейронной сети

Постоянные параметры, которые используются на всех вариантах обучения:

- Размер батча: 64;
- Функция потерь: перекрестная энтропия;
- Оптимизатор: Adam;
- Коэффициент L2 регуляризации: 0.02.

Сначала для каждого испытуемого нейронная сеть предобучалась на данных всех испытуемых, кроме целевого. Выборка из таких данных разбивалась на тренировочную и валидационную в процентном соотношении от общей выборки в 80% и 20% соответственно. При этом общая выборка включала в себя около 1800 движений. После аугментации временным сдвигом количество тренировочных данных увеличивалось в 5 раз и становилось около 7000. Также для предобучения нейронной сети были записаны реальные движения испытуемых. Включение их в обучающую выборку должно позволить изучить нейронной сети другие паттерны мозговой активности, возникающие при реальном движении, а также выделить общие паттерны реальных и воображаемых движений, так как они вместе находились в тренировочной выборке. Количество реальных движений составляло примерно 20% от общей выборки. В дальнейшем это позволяло незначительно улучшать показатели точности нейронной сети на 1-3%.

Начальная скорость обучения выставлялась довольно высокой: 0.003. Но для постепенного уменьшения скорости обучения использовалась модель из

библиотеки keras под названием ReduceLROnPlateau. Данная техника уменьшает скорость обучения на какой-то процент, когда целевая метрика перестает улучшаться за некоторое количество эпох. В данном случае коэффициент уменьшения скорости обучения был выбран 0.8, количество эпох – 20, а целевая метрика – значение функции потерь на валидационной выборке. Это означает, что если значение функции потерь не уменьшалось 20 эпох, то текущая скорость обучения уменьшается, умножаясь на коэффициент 0.8. Обучение запускалось на 1000 эпохах, но по результатам обучения бралась версия модели, которая показала лучший результат на валидационной выборке по значению функции потерь, что достигалось примерно на 400 эпохе. Выбор модели на основании значения точности классификации на валидационной выборке в дальнейшем приводил к ухудшению результатов по сравнению с выбором на основании значения функции потерь. На рисунке 7 представлен график обучения нейронной сети. Синий график представляет собой значение функции потерь на тренировочной выборке, а оранжевый – на валидационной.




Рисунок 7 – Значения функции потерь при обучении нейронной сети

Обучение нейросети на общих данных позволяет нейросети получить более полную картину о распределении данных, а также получить намного больше данных для тренировки, что позволяет лучше их обобщить. Далее предобученная нейросеть обучается на данных целевого испытуемого, которые она видит впервые. Данная техника в машинном обучении называется Transfer Learning.

Для оценки точности на данных конкретного испытуемого используется техника кросс-валидации. Создается 5 блоков различных обучающей, валидационной и тестовой выборок, которые в сумме дают полную выборку. После тренировки точность оценивается на тестовой выборке и усредняется по 5 блокам, показывая итоговую точность. Процент от общей выборки обучающей, валидационной и тестовой частей составляют соответственно 75%, 15% и 10%.

Обучение модели на данных испытуемого начинается с обучения последнего полносвязного слоя, в то время как веса всех остальных слоев заморожены. Это позволяет перебалансировать веса, последнего слоя, который отвечает за выходные нейроны, под конкретного испытуемого. При этом, веса нижних слоев, отвечающих за извлечение общих признаков остаются без изменений. Данная настройка производится всего на 5 эпохах с маленькой скоростью обучения в 0.0002. Далее запускается процесс обучения всей модели с той же начальной скоростью обучения. Также как и при обучении модели на общих данных, в данном случае используется техника понижения скорости обучения с коэффициентом уменьшения скорости обучения 0.7, количеством эпох 15, и целевой метрикой точность на валидационной выборке. После обучения на 500 эпохах выбиралась версия модели, показавшая лучшую точность на валидационной выборке, что обычно достигалось примерно на 200 эпохе. В данном случае выбор модели по метрике точности давал затем лучшие результаты на тестовой выборке по сравнению с выбором по значению функции потерь. На рисунке 8 можно видеть пример изменения точности классификации на тренировочной и

валидационной выборках по мере обучения. При этом, можно заметить, что исходная точность модели не равна 25%, что соответствует случайному выбору на 4 классах, так как модель была предобучена.




Рисунок 8 – Значения точности классификации при обучении нейронной сети

3.4 Используемые инструменты

Для разработки был выбран язык Python версии 3.9, так как в нем представлен широкий выбор инструментов для работы с данными и большой набор библиотек для машинного обучения. Использовались следующие библиотеки:

- tensorflow + keras. Библиотеки для построения и обучения нейронных сетей;
- numpy. Библиотека для работы с массивами данных, включающая в себя инструменты по их преобразованию и статистической обработке;

- mne, mne-realtime. Библиотека для работы с биомедицинскими сигналами, в том числе ЭЭГ данными. mne-realtime позволяет получать данные из LSL потока, для их обработки в реальном времени;
- scikit-learn. Библиотека для машинного обучения, предоставляющая большой набор полезных инструментов и алгоритмов.

4 РЕЗУЛЬТАТЫ ЭКСПЕРИМЕНТАЛЬНЫХ ИССЛЕДОВАНИЙ

4.1 Оценка способности испытуемых к совершению воображаемых движений

На первом этапе исследования были записаны данные 7 человек, по одному дню с каждым, всего около 200 движений на человека. Из них было 6 мужчин и одна женщина. Возрастная группа испытуемых была от 23 до 27 лет. Данных одного дня недостаточно для полноценной тренировки и тестирования нейронной сети, но достаточно для оценки способности человека к выполнению данной задачи. В настоящее время исследования [9] указывают на неспособность декодирования воображаемых движений у некоторого процента людей, что может быть обусловлено их физиологическими особенностями.

Для каждого человека была произведена оценка точности классификации с помощью техники кросс-валидации. Для одного человека, точность классификации движений составила примерно 25%, что соответствует случайному выбору для 4 классов и свидетельствует о неспособности нейронной сети найти какую-либо корреляцию между ЭЭГ данными и воображаемым движением. В последствии для этого человека был проведен дополнительный день для сбора данных и переоценка точности с учетом большего набора данных, но результат остался тем же. Примечательно то, что этот человек не выделяет у себя ведущей руки и выполняет разные задачи разными руками. Такая особенность у него сформировалась в детстве после перелома руки. Также в подростковом возрасте он проходил операцию по удлинению сломанной в детстве руки с помощью аппарата Илизарова. При этом испытуемый после записи ЭЭГ хорошо оценивал свою возможность к воображению движений и даже в течение недели тренировался этому вне записей ЭЭГ. Для остальных 6 людей результат был примерно одинаковый и точность классификации составляла 39-51%. Стоит отметить, что данная точность указана для моделей, обученных с использованием предобучения на общих данных, что значительно увеличивает точность при наличии

небольшого количества данных для конкретного человека. Для одного из этих 6 испытуемых, не удавалось получить точность более 25% без использования Transfer Learning.

4.2 Результаты эксперимента в оффлайн режиме

На втором этапе из этих 6 участников было отобрано 3 человека для дальнейшего сбора данных. С 1 испытуемым было проведено 5 дополнительных дней записи, а с 2 и 3 испытуемыми были проведены еще 3 дня записей. Далее, как было описано выше, сначала обучалась модель нейросети на всех собранных движениях всех участников, за исключением движений самого испытуемого и движений человека, которому не удалось продемонстрировать способность к воображаемым движениям. То есть каждая такая нейронная сеть училась на движениях 5 испытуемых. Затем модель дообучалась на данных целевого испытуемого. Итоговые результаты точности классификации для 3 испытуемых продемонстрированы в таблице 2. В данной таблице в том числе отображены результаты при различных способах обучения нейронной сети. Во всех случаях точность оценивалась по кросс-валидации.

Из таблицы следует, что наименьшая средняя точность в 43% достигается при обучении только на общих на данных, что является стандартным в подобных задачах. Обучение с использованием Transfer Learning позволило улучшить средний результат на 4%. При этом, у испытуемого с наименьшим показателем точности при обучении на одном испытуемом, точность выросла больше, чем у других испытуемых – на 9%. Это может свидетельствовать о том, что техника Transfer Learning лучше помогает тем, у кого хуже получается классифицировать воображаемые движения.

Таблица 2 – Точность классификации воображаемых движений для 3 испытуемых

	Точность классификации при различных типах обучения нейронной сети			Количество записанных движений
	Обучение только на общих данных, без данных испытуемого	Обучение только на данных испытуемого	Обучение на данных испытуемого после предобучения на общих данных	
Испытуемый 1	47%	63%	65%	1100
Испытуемый 2	39%	49%	58%	800
Испытуемый 3	43%	62%	64%	600
Среднее значение	43%	58%	62%	830

4.3 Результаты эксперимента в онлайн режиме

После проведения офлайн эксперимента был разработан онлайн режим, в котором пользователь может после воображения движения сразу получать обратную связь от нейросети в виде текстового указания определенного ею движения. Классификация воображаемого движения начиналась через некоторое время после нажатия испытуемым кнопки, сигнализирующей приложению о начале совершения движения. Взаимодействие с данным приложением дает пользователям возможность улучшать показатели точности распознавания их движений, так как в процессе работы с обратной связью они могут выявлять особенности работы алгоритма при различных вариантах воображения движений. Также после совершения движения на экране появлялась информация о вероятности отнесения нейронной сетью движения к каждому из классов. Это позволяло пользователю лучше понимать на сколько

нейросеть уверена в своем попадании или ошибке и давало ему возможность улучшать в процессе тренировки не только количество правильных вариантов, но и степень уверенности нейронной сети в них.

Одной из особенностей, с которой автор столкнулся во время тренировки испытуемых в онлайн режиме было различие результатов в разные дни тренировок. Это обусловлено тем, что ЭЭГ сигнал в той или иной степени меняется день ото дня, из-за различного наложения электродов, а также изменений в функциональном состоянии испытуемых и соответственно изменении работы их мозга. До сих пор большой проблемой в различных задачах декодирования информации из ЭЭГ является то, что обученный декодер для какого-то испытуемого может оказаться абсолютно неработающим для того же испытуемого через несколько месяцев, из-за изменений его мозговой активности. Поэтому, чтобы подробнее описать все детали, далее рассмотрим процесс тренировки каждого испытуемого отдельно.

4.3.1 Первый испытуемый

Для первого испытуемого было собрано самое большое количество данных в 6 разных дней. При этом сбор данных проходил в течение 3 месяцев с довольно равномерным распределением записей ЭЭГ по этим месяцам. Возможно такое широкое разнообразие временных участков в данных сделало нейронную сеть более стабильной и способной лучше сохранять свою работоспособность с течением времени. Далее этим испытуемым было проведено 3 сеанса тренировки в онлайн режиме в разные дни.

Первый сеанс тренировки был проведен спустя неделю после последней записи данных в оффлайн режиме. Точность классификации вначале тренировки составляла 64%, что примерно соответствует оценке по оффлайн данным. В конце первого дня точность составила 75%, что свидетельствует о прогрессе испытуемого.

Второй сеанс тренировки проходил спустя 3 недели после первого, что является значительным промежутком для ЭЭГ записей. На начало тренировки во второй день, точность классификации упала до 67%, что свидетельствует об изменении в состоянии испытуемого. Но за несколько минут тренировки вернулась к 75%, после чего перестала расти. Поэтому было записано около 100 движений, при которых испытуемого просили выполнять движения с учетом особенностей, которые он выучил в процессе тренировки. Например, при совершении правых и левых горизонтальных движений нейронная сеть чаще выдавала верный результат при совершении их в полностью расслабленном ментальном состоянии. В то время как правые и левые вертикальные движения лучше распознавались при полной концентрации на них. Разумеется, это все субъективные ощущения испытуемого, которые довольно сложно передать другому человеку, поэтому их описание поверхностное. Далее модель нейронной сети была еще раз доучена на сравнительно небольшом количестве таких новых данных, и тренировка испытуемого продолжилась с этой моделью, что положительно сказалось на результате. В конце второго дня точность классификации составила 81%.

Третий сеанс тренировки проходил спустя 1 неделю после второго. Начальная точность составила 75% и спустя несколько минут достигла значений предыдущего сеанса в 81%. Дальнейшая тренировка и еще одно дообучение сети на данных третьего дня улучшений не принесли и результат оставался таким же. Поэтому на этом было решено закончить попытки увеличения точности в онлайн режиме.

4.3.2 Второй испытуемый

Для второго испытуемого были собраны офлайн данные за 4 различных дня. При этом сбор проходил на небольшом временном отрезке – разница между первым и последним днем записи была 10 дней. Далее спустя полторы недели после записи офлайн данных были проведены онлайн тренировки в течение 2 дней подряд.

В первый день тренировки в онлайн режиме точность классификации в начале колебалась около значений, полученных в офлайн режиме – 56-60%. После часовой тренировки точность возросла и колебалась около 70%. Далее, как и для первого испытуемого, были записаны данные после онлайн тренировки с учетом лучшего понимания испытуемым того, как необходимо совершать воображаемые движения. Затем, по тем же принципам, модель была доучена, и тренировка продолжилась с обновленной нейронной сетью. В итоге точность классификации в конце первого дня составила 73%.

Во второй день тренировки, следовавшего сразу после первого, в начале точность, также как и для первого испытуемого, немного снизилась по сравнению с последними результатами прошлых тренировок и составила 70%. Но за небольшое количество времени тренировки стала чуть выше результата прошлого дня и достигла 75%. Далее, как и для первого испытуемого, точность переставала расти и держалась примерно на том же уровне в 75%. Еще одно доучивание модели также не приводило к улучшению результата. Поэтому на этом было решено остановить тренировки для второго испытуемого.

4.3.3 Третий испытуемый

Для третьего испытуемого офлайн данные были собраны в четыре различных дня. При этом первый день сбора данных был проведен с большим разрывом в 3 месяца относительно трех остальных дней, которые впоследствии были записаны за короткий промежуток времени в течение недели. Что удивительно, данные первого дня хорошо коррелировали с данными, записанными спустя 3 месяца. Это было выяснено путем обучения нейронной сети с различными тренировочными и тестовыми данными – если добавлять данные первого дня в тренировочную выборку, то результат на тестовой выборке, состоящей из данных 2, 3 и 4 дней, улучшался. Другими словами, паттерны первого дня, изученные нейронной сетью, оставались в некотором смысле полезными, даже через 3 месяца.

Онлайн эксперимент, в отличие от первых двух испытуемых, проводился спустя довольно долгое время после записи офлайн данных, на которых была обучена модель – через 2 месяца. Вероятнее всего это стало причиной его неудачи. На протяжении всей онлайн тренировки точность колебалась около 45%, что хуже, чем офлайн результаты. Следовательно, спустя 2 месяца модель стала менее эффективной и для нее требовались новые, более актуальные данные для обучения. В связи с этим эксперимент с третьим испытуемым было решено не продолжать.

4.3.4 Анализ результатов экспериментов в онлайн режиме

Несмотря на то, что для полного заключения необходимо провести исследования на гораздо большем количестве испытуемых, можно сделать некоторые выводы. ЭЭГ данные являются нестабильными во времени. У первых двух испытуемых точность классификации при начале тренировки падала на 3-8% относительно результатов последней записи. Это может быть как следствием различного наложения электродов и разных особенностей, связанных с чистотой кожи, так и изменений в функциональном состоянии испытуемых, включая изменения в зависимости от времени суток. Но для восстановления результатов обоим требовалась небольшая по времени настройка в 15-25 минут, для улучшения понимания того, как ведет себя алгоритм в текущий день. В итоге оба испытуемых продемонстрировали способность к обучению и в среднем смогли увеличить свои показатели как минимум на 11%. Но оба в какой-то момент достигали потолка, после которого дополнительные тренировки не давали улучшения. Для его достижения требовалось примерно 3-4 часа тренировок и дообучение нейронной сети, на данных записанных после тренировок.

Последний же испытуемый проводил онлайн тренировку спустя длительное время после записей офлайн данных и его результаты ухудшились. Хотя способность нейросети к классификации сильно ослабевает, она остается

даже спустя 2-3 месяца, о чем также свидетельствуют тесты с оффлайн данными, записанными в разное время.

ЗАКЛЮЧЕНИЕ

В ходе выполнения выпускной квалификационной работы были проанализированы существующие подходы к решению задач в области интерфейсов мозг-компьютер. На основе данного обзора и собранных с 7 испытуемых данных был реализован подход к классификации воображаемых движений на основе искусственных нейронных сетей.

Было предложено несколько улучшений в работе алгоритма, таких как использование реальных движений в обучении нейронной сети, аугментация данных временным сдвигом, использование новой архитектуры нейронной сети, а также применение нового подхода к обучению с использованием техники Transfer Learning. Последнее позволило улучшить точность классификации в среднем на 4%. Средняя точность классификации воображаемых движений в офлайн режиме составила 62%. Также было выявлено, что для 1 из 7 человек, оказалось невозможным получить точность классификации более 25%, что соответствует случайному угадыванию для 4 классов.

Далее был проведен онлайн эксперимент с целью улучшения точности классификации за счет тренировки испытуемых с обратной связью. В качестве обратной связи предложено предоставлять испытуемому не только декодированное алгоритмом движение, но и вероятность отнесения движения к каждому классу, что давало испытуемому гораздо больше информации, на которую можно опираться при изучении работы алгоритма. Двое из трех испытуемых смогли улучшить свои показатели точности в среднем на 11%. После 15-25 минутной настройки испытуемых на обратной связи от алгоритма в текущий день точность повышалась еще на 3-6%. Но также остались вопросы, требующие дальнейшего исследования, заключающиеся в стабильности точности классификации модели с течением времени. Так, для 3 испытуемого результат ухудшился спустя 2 месяца после записи данных для обучения, что не помешало его тренировке в онлайн режиме.

По результатам работы была принята к публикации статья «Лунев А.Е., Билый А.М. Классификация воображаемых движений рук человека на основе данных электроэнцефалографии // Вестник психофизиологии (ВАК, РИНЦ)».

Таким образом, все поставленные задачи были выполнены, и цель работы достигнута.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Saha S. et al. Progress in brain computer interface: Challenges and opportunities //Frontiers in systems neuroscience. – 2021. – Т. 15. – С. 578875 (дата обращения 12.11.2022).
2. Cho W. et al. Motor rehabilitation for hemiparetic stroke patients using a brain-computer interface method //2018 IEEE International Conference on Systems, Man, and Cybernetics (SMC). – IEEE, 2018. – С. 1001-1005 (дата обращения 15.09.2023).
3. Monge-Pereira E. et al. Use of electroencephalography brain-computer interface systems as a rehabilitative approach for upper limb function after a stroke: a systematic review //PM&R. – 2017. – Т. 9. – №. 9. – С. 918-932 (дата обращения 19.01.2024).
4. Yakovlev L. et al. BCI-controlled motor imagery training can improve performance in e-sports //HCI International 2020-Posters: 22nd International Conference, HCII 2020, Copenhagen, Denmark, July 19–24, 2020, Proceedings, Part I 22. – Springer International Publishing, 2020. – С. 581-586 (дата обращения 02.02.2024).
5. Wang L. et al. Improvement of mental tasks with relevant speech imagery for brain-computer interfaces //Measurement. – 2016. – Т. 91. – С. 201-209 (дата обращения 25.06.2023).
6. Kosmyna N., Lindgren J. T., Lécuyer A. Attending to visual stimuli versus performing visual imagery as a control strategy for EEG-based brain-computer interfaces //Scientific reports. – 2018. – Т. 8. – №. 1. – С. 13222 (дата обращения 28.06.2023).
7. Phadikar S., Sinha N., Ghosh R. Unsupervised feature extraction with autoencoders for EEG based multiclass motor imagery BCI //Expert Systems with Applications. – 2023. – Т. 213. – С. 118901 (дата обращения 10.12.2022).

8. Korik A. et al. Decoding imagined 3D arm movement trajectories from EEG to control two virtual arms—a pilot study //Frontiers in neurorobotics. – 2019. – Т. 13. – С. 94 (дата обращения 10.11.2022).
9. Pérez-Velasco S. et al. EEGSym: Overcoming inter-subject variability in motor imagery based BCIs with deep learning //IEEE Transactions on Neural Systems and Rehabilitation Engineering. – 2022. – Т. 30. – С. 1766-1775 (дата обращения 14.07.2023).
10. Lawhern V. J. et al. EEGNet: a compact convolutional neural network for EEG-based brain–computer interfaces //Journal of neural engineering. – 2018. – Т. 15. – №. 5. – С. 056013 (дата обращения 02.03.2023).
11. Ingolfsson T. M. et al. EEG-TCNet: An accurate temporal convolutional network for embedded motor-imagery brain–machine interfaces //2020 IEEE International Conference on Systems, Man, and Cybernetics (SMC). – IEEE, 2020. – С. 2958-2965 (дата обращения 04.03.2023).
12. Altaheri H., Muhammad G., Alsulaiman M. Physics-informed attention temporal convolutional network for EEG-based motor imagery classification //IEEE transactions on industrial informatics. – 2022. – Т. 19. – №. 2. – С. 2249-2258 (дата обращения 07.03.2023).
13. Brunner C. et al. BCI Competition 2008–Graz data set A //Institute for Knowledge Discovery (Laboratory of Brain-Computer Interfaces), Graz University of Technology. – 2008. – Т. 16. – С. 1-6 (дата обращения 01.03.2023).
14. Aggarwal S., Chugh N. Signal processing techniques for motor imagery brain computer interface: A review //Array. – 2019. – Т. 1. – С. 100003 (дата обращения 15.12.2022).
15. Курганский А. В. Некоторые вопросы исследования корково-корковых функциональных связей с помощью векторной авторегрессионной модели многоканальной ЭЭГ //Журнал высшей нервной деятельности им. ИП Павлова. – 2010. – Т. 60. – №. 6. – С. 740-759 (дата обращения 18.12.2022).

16. Zhong M. et al. EEG emotion recognition based on TQWT-features and hybrid convolutional recurrent neural network //Biomedical signal processing and control. – 2023. – Т. 79. – С. 104211 (дата обращения 20.12.2022).
17. Malik W. Q. et al. Efficient decoding with steady-state Kalman filter in neural interface systems //IEEE Transactions on Neural Systems and Rehabilitation Engineering. – 2010. – Т. 19. – №. 1. – С. 25-34 (дата обращения 17.12.2022).
18. Faller J. et al. Autocalibration and recurrent adaptation: Towards a plug and play online ERD-BCI //IEEE Transactions on Neural Systems and Rehabilitation Engineering. – 2012. – Т. 20. – №. 3. – С. 313-319 (дата обращения 23.12.2022).
19. Капралов Н. В., Нагорнова Ж. В., Шемякина Н. В. Методы классификации ЭЭГ-паттернов воображаемых движений //Информатика и автоматизация. – 2021. – Т. 20. – №. 1. – С. 94-132 (дата обращения 11.07.2023).
20. Ang K. K. et al. Filter bank common spatial pattern (FBCSP) in brain-computer interface //2008 IEEE international joint conference on neural networks (IEEE world congress on computational intelligence). – IEEE, 2008. – С. 2390-2397 (дата обращения 14.12.2022).
21. Dal Seno B., Matteucci M., Mainardi L. A genetic algorithm for automatic feature extraction in P300 detection //2008 IEEE International joint conference on neural networks (IEEE World congress on computational intelligence). – IEEE, 2008. – С. 3145-3152 (дата обращения 24.08.2023).
22. Sagee G. S., Hema S. EEG feature extraction and classification in multiclass multiuser motor imagery brain computer interface using Bayesian Network and ANN //2017 International Conference on Intelligent Computing, Instrumentation and Control Technologies (ICICICT). – IEEE, 2017. – С. 938-943 (дата обращения 15.12.2022).
23. Кирой В. и др. Нейротехнологии: Нейро-БОС и интерфейс «мозг–компьютер». – Litres, 2018 (дата обращения 20.11.2022).

24. Constantine A. et al. Bci system using a novel processing technique based on electrodes selection for hand prosthesis control //IFAC-PapersOnLine. – 2021. – Т. 54. – №. 15. – С. 364-369 (дата обращения 19.12.2022).
25. Temiyasathit C. et al. Increase performance of four-class classification for motor-imagery based brain-computer interface //2014 International Conference on Computer, Information and Telecommunication Systems (CITS). – IEEE, 2014. – С. 1-5 (дата обращения 15.03.2023).
26. Aler R., Galván I. M., Valls J. M. Evolving spatial and frequency selection filters for brain-computer interfaces //IEEE congress on evolutionary computation. – IEEE, 2010. – С. 1-7 (дата обращения 05.08.2023).
27. Guan S. et al. Motor imagery EEG classification based on decision tree framework and Riemannian geometry //Computational intelligence and neuroscience. – 2019. – Т. 2019 (дата обращения 12.05.2023).
28. Singh A., Lal S., Guesgen H. W. Reduce calibration time in motor imagery using spatially regularized symmetric positives-definite matrices based classification //Sensors. – 2019. – Т. 19. – №. 2. – С. 379 (дата обращения 15.05.2023).
29. Lee H. K., Choi Y. S. A convolution neural networks scheme for classification of motor imagery EEG based on wavelet time-frequency image //2018 International Conference on Information Networking (ICOIN). – IEEE, 2018. – С. 906-909 (дата обращения 21.02.2023).
30. Zhang J., Yan C., Gong X. Deep convolutional neural network for decoding motor imagery based brain computer interface //2017 IEEE international conference on signal processing, communications and computing (ICSPCC). – IEEE, 2017. – С. 1-5 (дата обращения 23.02.2023).
31. Li Y. et al. A channel-projection mixed-scale convolutional neural network for motor imagery EEG decoding //IEEE Transactions on Neural Systems

and Rehabilitation Engineering. – 2019. – Т. 27. – №. 6. – С. 1170-1180 (дата обращения 25.02.2023).